Taller 2 Sistemas Avanzados de Producción

Liseth Johana Duarte Jaime Cod. 75157

Gineth Vanessa Robayo Bustamante Cod. 60881

María Camila Castelblanco Ruiz Cod. 111924

Presentado a: Docente; Fredy Alexander Orjuela López

Universidad Ecci

Sistemas Avanzados de producción

Ingeniería Industrial

Bogotá

2026

Semana 6

GitHub: Semana 6 - Descenso de Gradiente.

Ubique el último bloque de código donde se configura la simulación:

```
# --- CONFIGURACIÓN DE LA SIMULACIÓN ---
start_point = [0.0, 0.1]     # Punto de inicio
learning_rate = 0.0001       # Tasa de aprendizaje (eta)
num_iterations = 1000        # Número de pasos
```

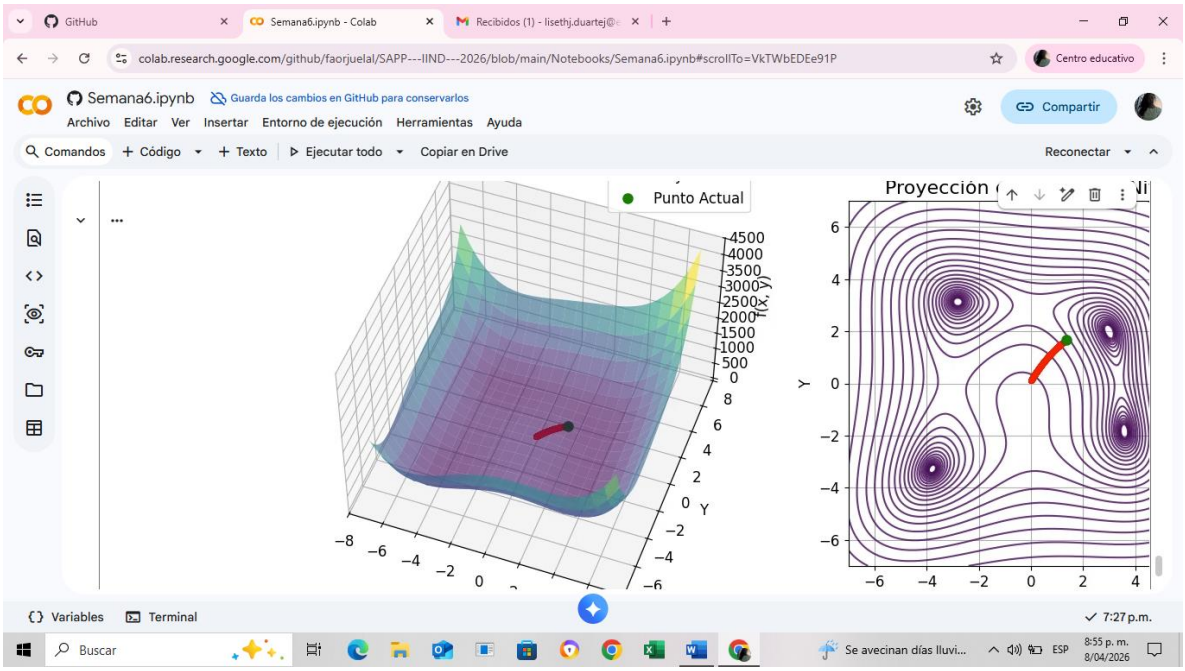

Este es el resultado inicial donde se puede observar que el gradiente se dirige al punto mínimo.

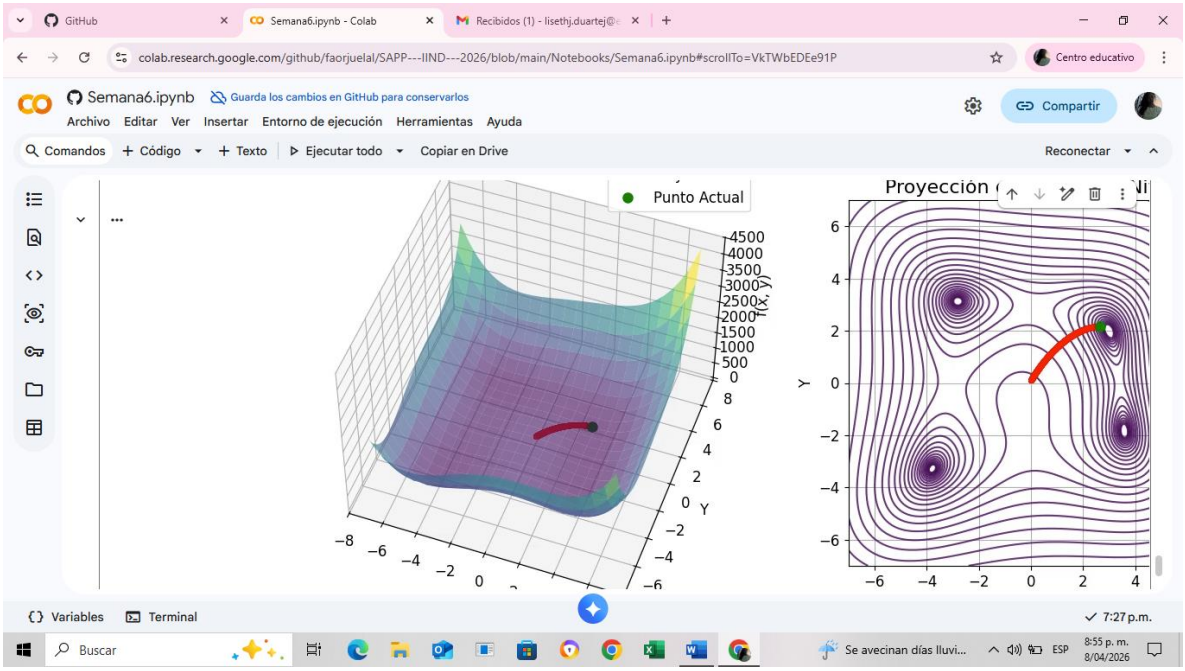

[5]
7 m

```
        # Actualiza la posición del punto
        point = point - learning_rate * grad

    return np.array(path)

# --- CONFIGURACIÓN DE LA SIMULACIÓN ---
# Punto de inicio (puedes cambiarlo para ver cómo cae en otro mínimo)
start_point = [0.0, 0.1]
learning_rate = 0.0005      # Tasa de aprendizaje
num_iterations = 1000       # Número de pasos
```

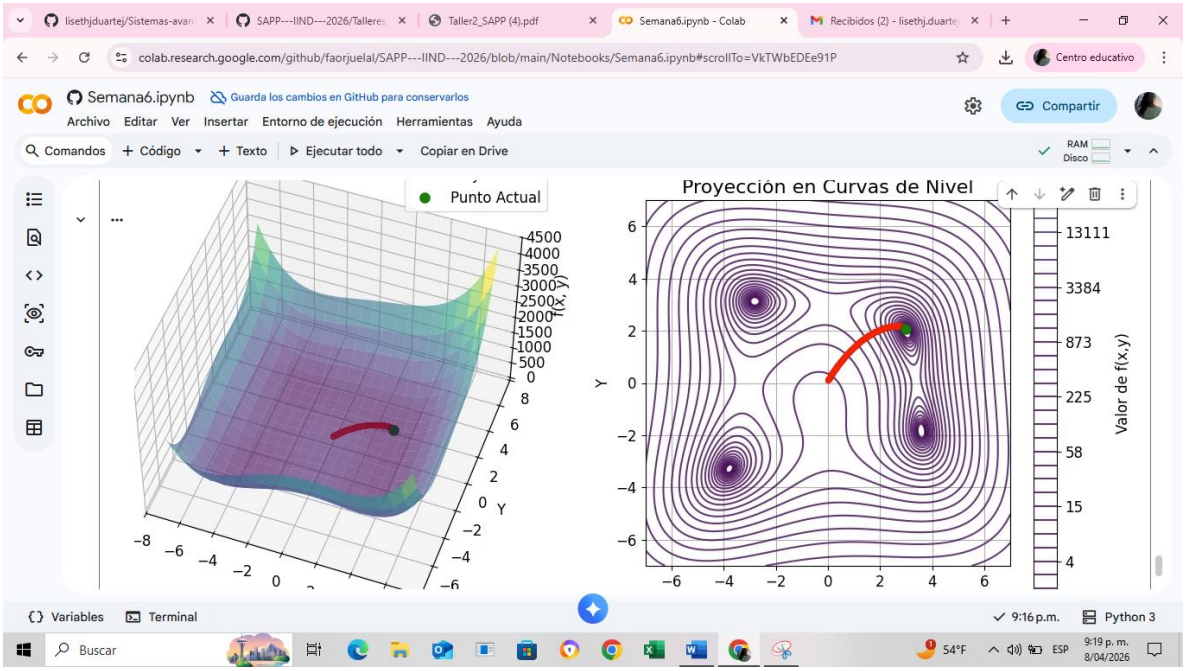

Con un learnig-rate de 0,005 podemos observar que el gradiente también se dirige al punto mínimo

```
[6]
✓ 7 m
# --- CONFIGURACION DE LA SIMULACION ---
# Punto de inicio (puedes cambiarlo para ver cómo cae en otro mínimo)
start_point = [0.0, 0.1]
learning_rate = 0.00000001      # Tasa de aprendizaje
num_iterations = 1000       # Número de pasos
```

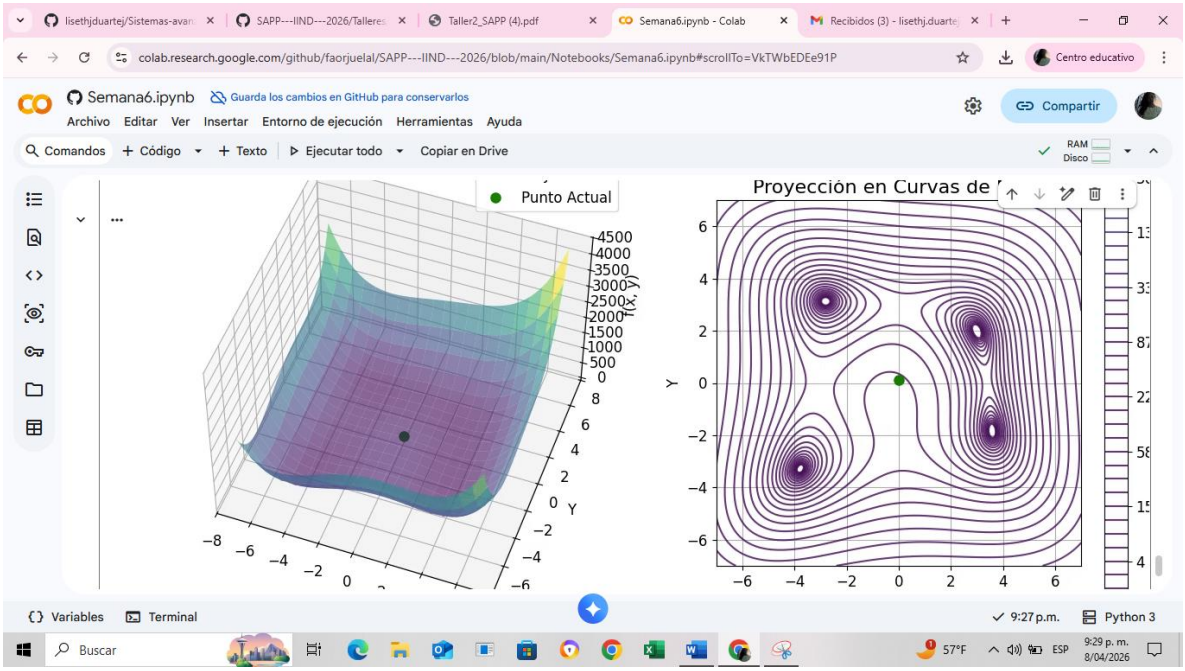

El learning-rate está en (10^{-7}) por lo tanto la trayectoria no se mueve queda quieta, porque el paso es muy pequeño y no se logra observar que avance hacia el punto mínimo.

```
[7]
✓ 7 m
    return np.array(path)

# --- CONFIGURACIÓN DE LA SIMULACIÓN ---
# Punto de inicio (puedes cambiarlo para ver cómo cae en otro mínimo)
start_point = [6.0, -0.6]
learning_rate = 0.00000001      # Tasa de aprendizaje
num_iterations = 1000       # Número de pasos
```

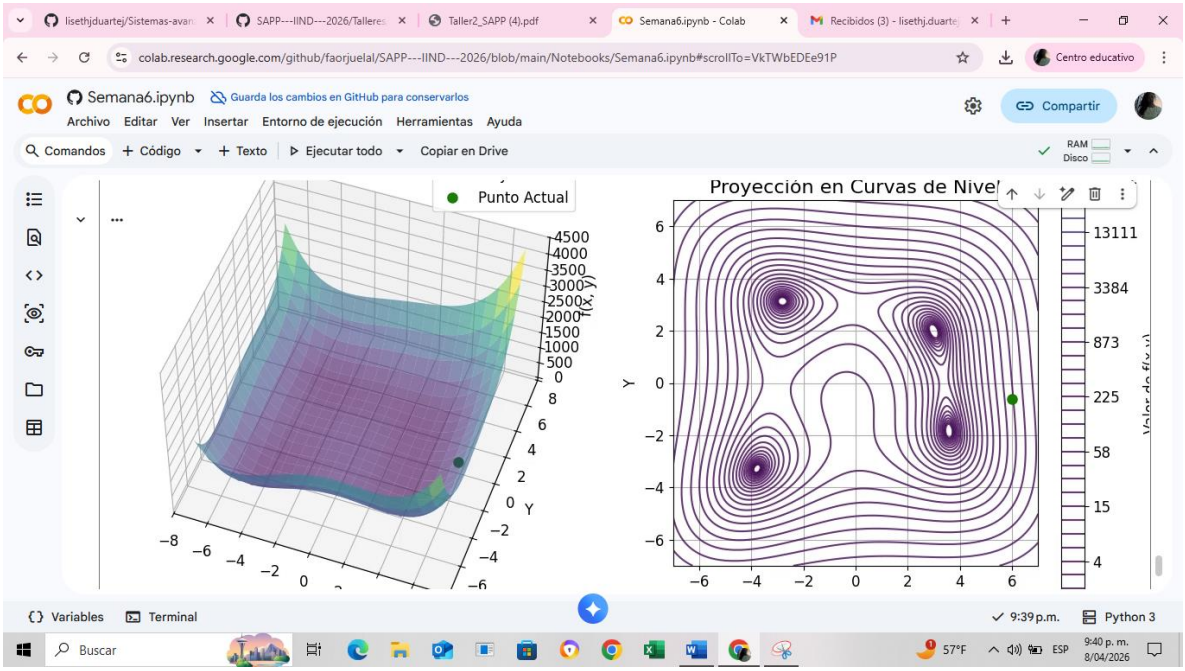

No hay trayectoria porque el learning-rate está en (10^{-7}) entonces tenemos un paso muy pequeño, y el star-point al tener estos valores de 6.0 y -6.0 cambia el gradiente.

```
[8]
7 m
# --- CONFIGURACION DE LA SIMULACION ---
# Punto de inicio (puedes cambiarlo para ver cómo cae en otro mínimo)
start_point = [6.0, -0.6]
learning_rate = 0.0001      # Tasa de aprendizaje
num_iterations = 1000       # Número de pasos
```

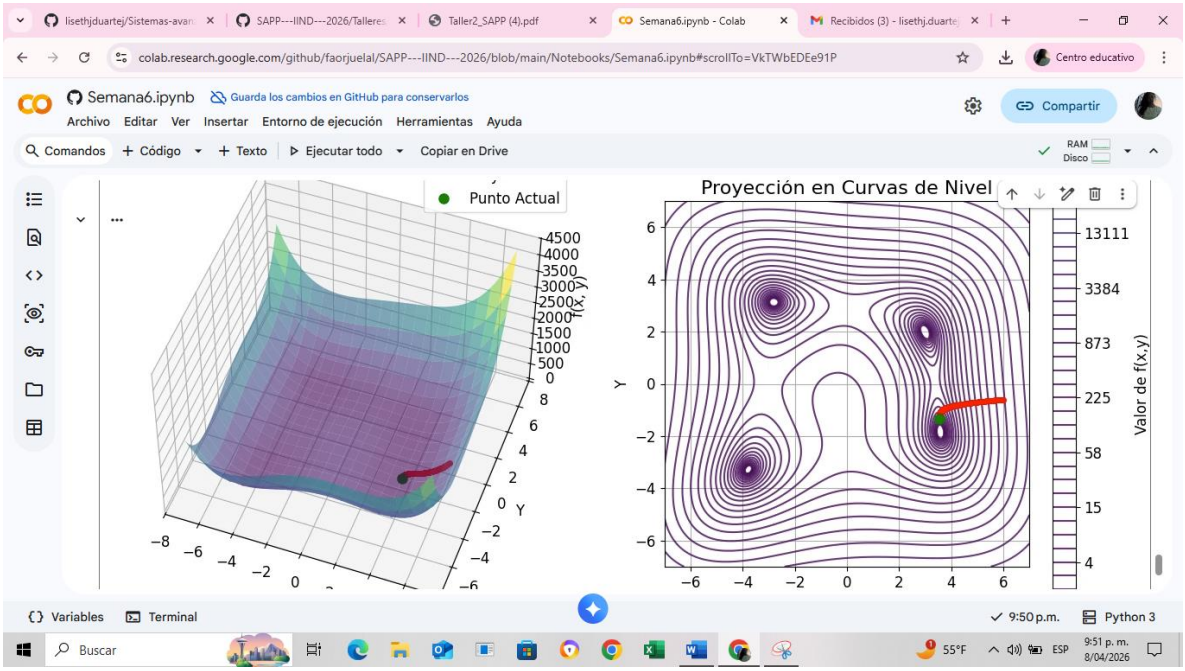

Al tener un learning-rate de 0.0001 vemos que el gradiente se mueve hacia el punto minino.

```
# --- CONFIGURACIÓN DE LA SIMULACIÓN ---
# Punto de inicio (puedes cambiarlo para ver cómo cae en otro mínimo)
start_point = [0.0, 0.1]
learning_rate = 0.5      # Tasa de aprendizaje
num_iterations = 1000       # Número de pasos
```

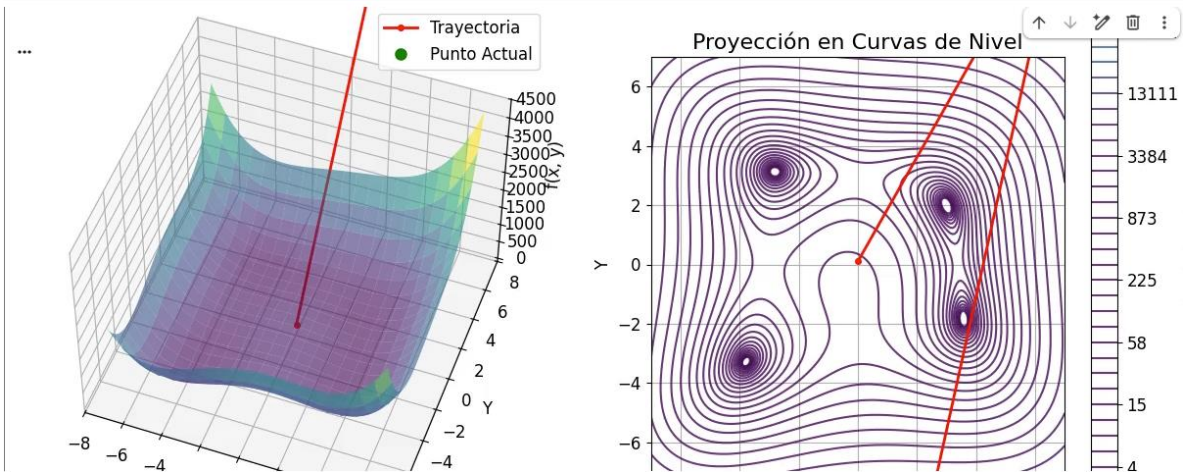

El gradiente cambia de dirección y no llega al punto mínimo

Preguntas Fase 2

El fenómeno de “Overshooting”: Explique físicamente que ocurre cuando el paso ($\eta \cdot \nabla f$) es más grande que la distancia al mínimo. ¿Como se visualiza esto en el gráfico de curvas de nivel?

RTA: No se detiene en el mínimo; se sobrepasa y termina en otro lado y el gradiente cambiara de dirección. Empieza a **oscilar alrededor del mínimo** sin converger, o incluso puedes alejarte completamente si los pasos son muy grandes.

- Si η\etaη es pequeño → convergencia lenta pero estable.
- Si η\etaη es adecuado → convergencia rápida.
- Si η\etaη es muy grande → **overshooting** (inestabilidad).

Eficiencia Computacional: Si el algoritmo se detiene en la iteración 1000 pero aún se encuentra lejos del mínimo, ¿qué estrategia es mejor: aumentar el número de iteraciones o ajustar la tasa de aprendizaje? Justifique su respuesta.

Si después de 1000 iteraciones el algoritmo **aún está lejos del mínimo**, la mejor estrategia es **ajustar la tasa de aprendizaje (η)**, no simplemente aumentar el número de iteraciones, al realizarlo se acelera la convergencia y se llega al mínimo en menos iteraciones y si se disminuye se estabiliza la trayectoria hacia el mínimo.

En términos computacionales entre mas iteraciones mayor costo, mismo problema, si el número de pasos es mejor obtenemos menos iteraciones, mejor convergencia.

En conclusión, se ajusta η **mejora la eficiencia del algoritmo**, mientras que aumentar iteraciones solo incrementa el tiempo de cómputo sin garantizar resultados.

Generalización: En un problema de ingeniería con cientos de variables (como la optimización de una cadena de suministro), ¿porque es peligroso confiar en un único punto de inicio aleatorio?

Confiar en **un único punto de inicio aleatorio** en problemas con muchas variables (alta dimensionalidad) es peligroso porque aumenta significativamente el riesgo de obtener **soluciones pobres o engañosas**. En contextos como la optimización de una cadena de suministro, esto afecta directamente la calidad de las decisiones.

Confiar en un solo punto inicial en problemas de alta dimensión es riesgoso porque: No explora adecuadamente el espacio de soluciones, puede llevar a mínimos locales, reduce la confiabilidad y robustez del resultado

Esto puede traducirse en **decisiones costosas o ineficientes**, por lo que siempre es mejor explorar múltiples puntos de partida.

SEMANA 7

Parte A: Evaluación de Métricas de Regresión Ejecute el modelo MLP Regressor inicial con la configuración base (hidden layer sizes = (16, 8, 4)). Observe los resultados de las métricas MAE, RMSE y R2 tanto para el conjunto de entrenamiento como para el de prueba (test).

https://colab.research.google.com/drive/1WTvzWOPr2C7UGsTDcrTdlkqYZaWJJltl

SEMANA 9

	UDI	Product ID	Type	Air temperature [K]	Process temperature [K]	Rotational speed [rpm]	Torque [Nm]	Tool wear [min]	Machine failure	TWF	HDF	PWF	OSF	RNF
0	1	M14860	M	298.1	308.6	1551	42.8	0	0	0	0	0	0	0
1	2	L47181	L	298.2	308.7	1408	46.3	3	0	0	0	0	0	0
2	3	L47182	L	298.1	308.5	1498	49.4	5	0	0	0	0	0	0
3	4	L47183	L	298.2	308.6	1433	39.5	7	0	0	0	0	0	0
4	5	L47184	L	298.2	308.7	1408	40	9	0	0	0	0	0	0

Se identifican **columnas clave** como:

Temperaturas: Air temperature [K] y Process temperature [K]
Variables operativas: Rotational speed [rpm], Torque [Nm], Tool wear [min]
Variable objetivo: Machine failure (indica si hubo falla)
Tipos de falla específicos: TWF, HDF, PWF, OSF, RNF
Clasificación del producto: Type (L, M, H)

Análisis técnico inicial

- Este conjunto de datos corresponde a un problema típico de **mantenimiento predictivo**, donde se busca anticipar fallas en maquinaria a partir de variables operativas.
- La variable Machine failure sugiere un enfoque de **clasificación binaria** (0 = no falla, 1 = falla).
- Las variables adicionales de fallas específicas permiten un análisis más detallado del tipo de fallo, lo que puede enriquecer modelos más avanzados.
- Las primeras filas muestran valores consistentes, sin evidencia inmediata de datos nulos o errores visibles.

Se realizó la carga del dataset ai4i2020.csv en el entorno de Google Colab utilizando la librería panda. Posteriormente, se visualizaron las primeras cinco filas del conjunto de datos con el fin de verificar su correcta importación.

Los resultados evidencian que el dataset contiene información estructurada sobre variables operativas de maquinaria industrial, incluyendo temperatura, velocidad de rotación, torque y

desgaste de herramienta. Asimismo, se identifica una variable objetivo denominada “Machine failure”, la cual permite analizar la ocurrencia de fallas, junto con variables adicionales que clasifican tipos específicos de fallos.

En general, los datos presentan consistencia en su estructura, lo que permite avanzar hacia etapas posteriores de análisis exploratorio y modelamiento.

El conjunto de datos analizado está compuesto por 10.000 registros y 14 variables, incluyendo variables numéricas y categóricas relacionadas con el desempeño de maquinaria industrial. A partir del análisis exploratorio, se evidenció que no existen valores nulos, lo cual garantiza la calidad e integridad de la información.

Las variables térmicas presentan baja variabilidad, mientras que variables como la velocidad de rotación, el torque y el desgaste de herramienta muestran mayor dispersión, lo que las convierte en factores relevantes para el análisis.

Por otra parte, la variable objetivo “Machine failure” presenta un marcado desbalance, con una baja proporción de fallas (3.39%), lo cual debe ser considerado en etapas posteriores de modelamiento. Asimismo, los tipos específicos de fallas analizados corresponden a eventos poco frecuentes, lo que refuerza la necesidad de un enfoque detallado en el análisis predictivo.

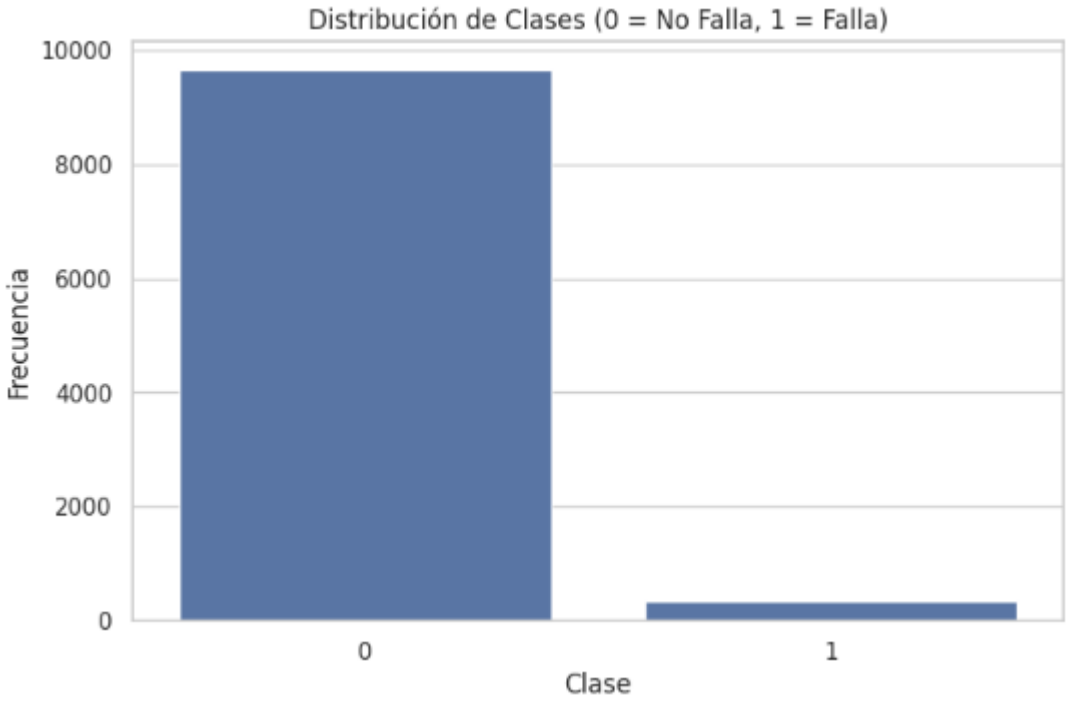

El análisis de la variable objetivo “Machine failure” evidencia un marcado desbalance en las clases, donde el 96.61% de los registros corresponden a condiciones normales de operación (sin falla), mientras que solo el 3.39% representan eventos de falla.

Esta distribución es característica de problemas de mantenimiento predictivo, en los cuales las fallas son eventos poco frecuentes. Sin embargo, este desbalance puede afectar el desempeño de modelos de clasificación, generando sesgos hacia la clase mayoritaria.

Por lo tanto, es necesario considerar técnicas de balanceo de datos y el uso de métricas de evaluación adecuadas que permitan medir correctamente la capacidad del modelo para identificar fallas.

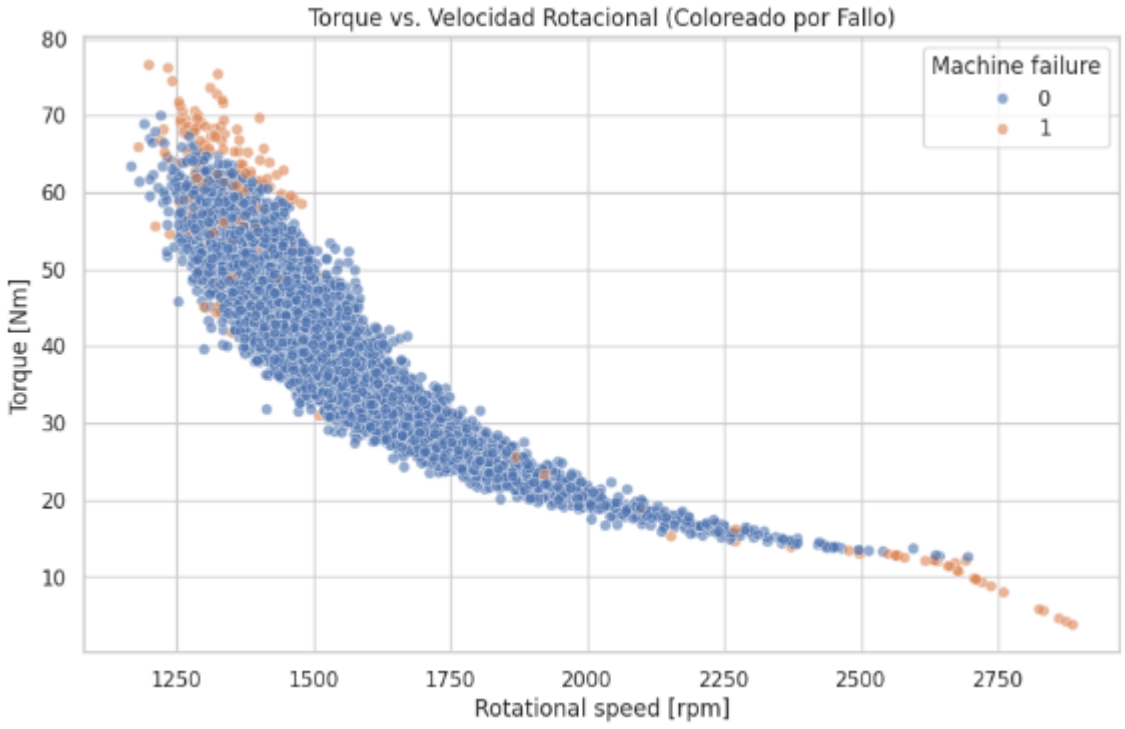

Relación entre variables

Se observa una relación inversa clara entre el torque y la velocidad de rotación:

A mayor velocidad de rotación, el torque disminuye

A menor velocidad, el torque tiende a ser más alto

El análisis de dispersión entre el torque y la velocidad de rotación evidencia una relación inversa entre ambas variables, donde a medida que aumenta la velocidad, el torque tiende a disminuir. Este comportamiento es consistente con principios mecánicos de operación.

Adicionalmente, al incorporar la variable de fallo, se observa que los eventos de falla no se distribuyen de manera aleatoria, sino que se concentran principalmente en zonas de alto torque y velocidades bajas o medias.

Este hallazgo sugiere la existencia de condiciones operativas críticas que incrementan la probabilidad de fallo, lo que resalta la importancia de estas variables en el desarrollo de modelos predictivos y estrategias de mantenimiento.

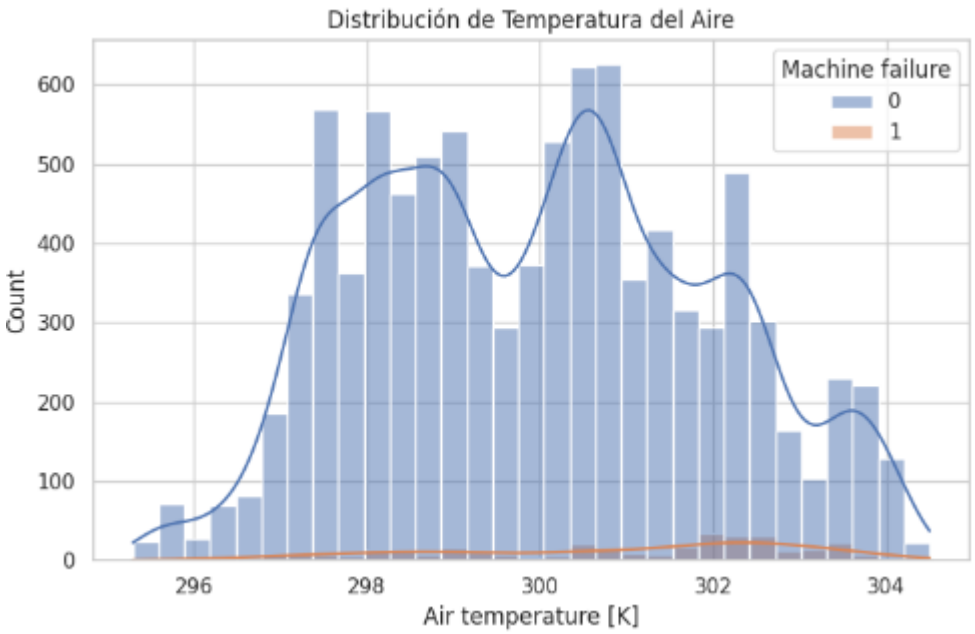

Comportamiento general

La temperatura del aire se distribuye aproximadamente entre 295 K y 304 K.

La mayor concentración de datos se encuentra alrededor de los 300 K, lo que indica una distribución relativamente centrada y estable.

Se observa una forma cercana a una distribución normal, aunque con ligeras variaciones.

El análisis de la distribución de la temperatura del aire muestra que esta variable presenta un comportamiento estable, con valores concentrados alrededor de los 300 K y una dispersión relativamente baja.

Al comparar la distribución entre casos de falla y no falla, no se observa una separación clara entre ambas clases, lo que indica que la temperatura del aire, de forma individual, no es un factor determinante en la ocurrencia de fallas.

No obstante, se identifica una ligera tendencia de los eventos de falla hacia valores más altos de temperatura, lo que sugiere que esta variable podría tener un efecto complementario cuando se analiza en conjunto con otras variables operativas.

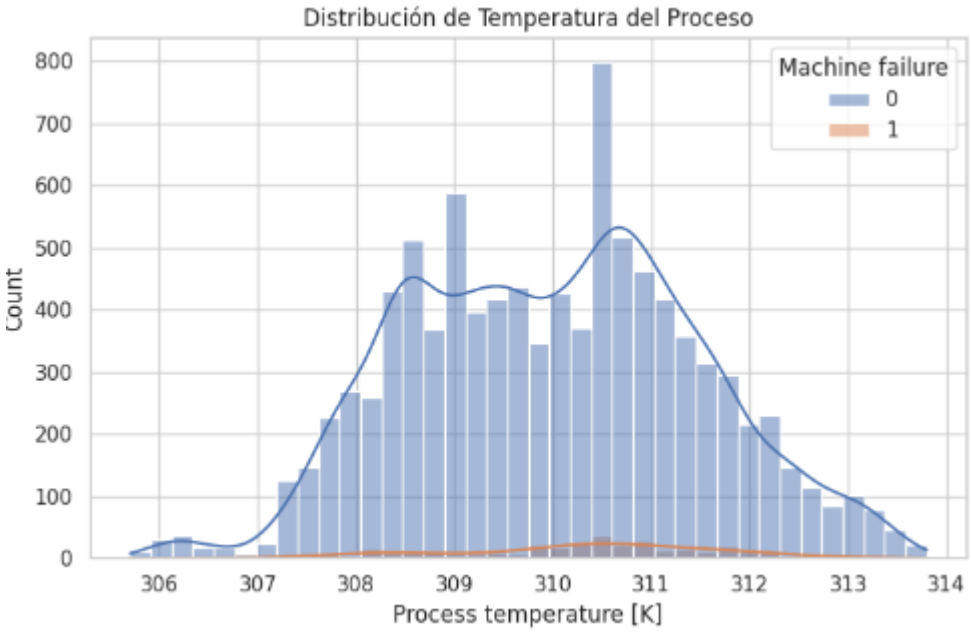

El gráfico muestra la distribución de la temperatura del proceso (K), diferenciando entre condiciones de operación normal y eventos de falla (Machine failure).

Hallazgos clave

La temperatura del proceso muestra un comportamiento estable pero más concentrado que la temperatura del aire.
Existe una leve tendencia de las fallas hacia valores altos.
No hay una separación clara entre clases, por lo que:
No es una variable determinante por sí sola
Pero sí puede ser relevante en combinación con otras variables

El análisis de la temperatura del proceso evidencia una distribución concentrada en torno a los 310 K, con un comportamiento estable y baja variabilidad.

Al comparar los casos de falla y no falla, no se observa una separación clara entre ambas clases; sin embargo, se identifica una ligera tendencia de los eventos de falla hacia valores más altos de temperatura del proceso.

Este resultado sugiere que, aunque la variable no es determinante de manera individual, podría influir en la ocurrencia de fallas cuando se combina con otras variables operativas, especialmente aquellas relacionadas con carga mecánica y condiciones de operación.

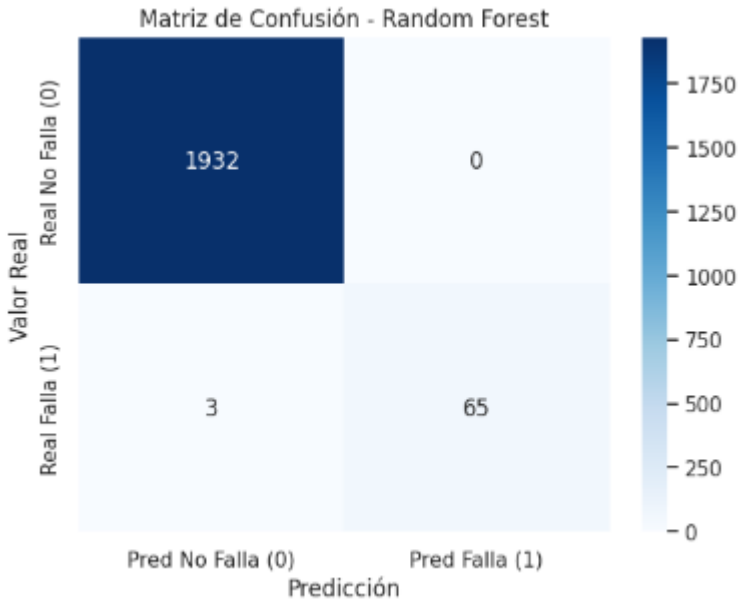

El modelo tiene un desempeño excelente:
No genera falsas alarmas (FP = 0)
Detecta casi todas las fallas
El único punto de mejora:
Hay 3 fallas que no fueron detectadas (FN)

La matriz de confusión del modelo Random Forest evidencia un alto desempeño en la clasificación de fallas. El modelo logró identificar correctamente 1932 casos sin falla y 65 casos con falla, sin generar falsos positivos.

Adicionalmente, se registraron únicamente 3 falsos negativos, lo que indica que el modelo presenta una alta capacidad de detección de eventos críticos.

En términos generales, el modelo demuestra ser altamente preciso y confiable para aplicaciones de mantenimiento predictivo, aunque se recomienda evaluar estrategias que permitan reducir aún más los falsos negativos, debido a su impacto en entornos reales.

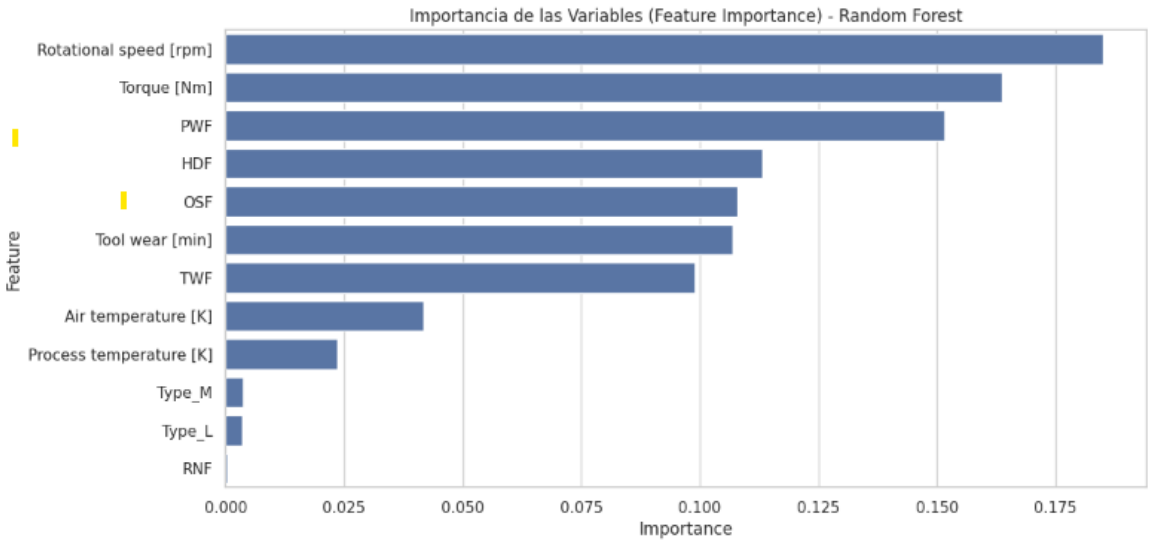

El gráfico muestra la relevancia relativa de cada característica (feature) en la capacidad predictiva del modelo de Random Forest. La importancia se mide generalmente a través de la reducción de la impureza (Gini importance), lo que indica qué variables facilitan mejor la división de los datos para llegar a una predicción correcta.

Si se tuviera que optimizar el proceso o monitorear fallas, los esfuerzos deben centrarse prioritariamente en el control de la velocidad rotacional y el torque. Las variables de tipo de producto (Type_L/M) podrían incluso ser eliminadas en una etapa de simplificación del modelo (feature selection) sin afectar significativamente el rendimiento.

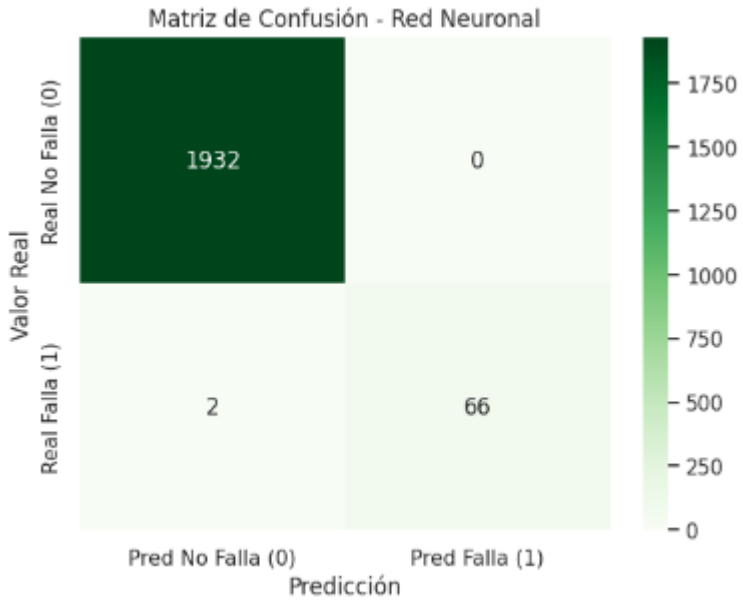

Desbalance de Clases: Se observa un desbalance evidente (muchas más "No Fallas" que "Fallas"). Sin embargo, la Red Neuronal lo está manejando muy bien, ya que no se sesgó totalmente hacia la clase mayoritaria.

Poder de Detección: Un *Recall* del 97% con una *Precisión* del 100% es un resultado excepcional. Indica que la red neuronal ha aprendido patrones muy específicos que distinguen la falla de la operación normal.

Riesgo Residual: Los **2 Falsos Negativos** son el único punto de atención. En un entorno real, habría que analizar qué características tenían esos dos casos para entender por qué la red no los detectó.

La Red Neuronal tiene un desempeño casi perfecto. Es un modelo altamente confiable para ser implementado, ya que garantiza cero falsas alarmas y una tasa de detección de fallas muy alta.

Matriz:

capa 1 (oculta) =

$$W^{(1)} = \begin{pmatrix} 0,2 & 0,5 & -0,1 \\ 0,8 & -0,3 & 0,4 \\ -0,5 & 0,1 & 0,2 \end{pmatrix} \quad b^{(1)} = \begin{pmatrix} 0,1 \\ -0,2 \\ 0,0 \end{pmatrix}$$

$$W^{(2)} = \begin{pmatrix} 0,5 & -0,4 & 0,1 \\ 0,2 & 0,8 & -0,5 \\ -0,1 & 0,3 & 0,7 \end{pmatrix} \quad b^{(2)} = \begin{pmatrix} -0,1 \\ 0,2 \\ 0,1 \end{pmatrix}$$

- vector de entrada $X = [0,5 ; 0,3 ; 0,2]^T$

x_1	x_2	x_3
0,5	0,3	0,2

$$\begin{bmatrix} w_{11} & w_{21} & w_{31} \\ w_{12} & w_{22} & w_{32} \\ w_{13} & w_{23} & w_{23} \end{bmatrix}$$

$z_1 = W^T X + \text{sesgo}$

$z_1 = w_{11} \cdot x_1 + w_{21} \cdot x_2 + w_{31} \cdot x_3 + b_1$

$\Rightarrow 0,2 \cdot 0,5 + 0,8 \cdot 0,3 + (-0,5) \cdot 0,2 + 0,1$

$\Rightarrow 0,184$

$z_2 = w_{21} \cdot x_1 + w_{22} \cdot x_2 + w_{23} \cdot x_3 + b_2$

$\Rightarrow 0,5 \cdot 0,5 + (-0,3) \cdot 0,3 + 0,1 \cdot 0,2 + (-0,2)$

$\Rightarrow 0,44$

$$z_3 = w_{31} \cdot x_1 + w_{32} \cdot x_2 + w_{33} \cdot x_3 + b_3$$

$$\Rightarrow (0,1 \cdot 0,5) + 0,4 \cdot 0,3 + 0,2 \cdot 0,2 + 0,0$$

$$\Rightarrow 0,11$$

- Se aplica =

$$f = \frac{1}{1+e^{-z}}$$

$$z_1 = \frac{1}{1+e^{-0,154}} = 0,5458$$

$$z_2 = \frac{1}{1+e^{-0,44}} = 0,3917$$

$$z_3 = \frac{1}{1+e^{-0,11}} = 0,5274$$

FASE 5:

CODIGO:

```
[3]
# URL del dataset en el repositorio de UCI
url = "/content/ai4i2020.csv"

# Cargar los datos en un DataFrame de pandas
df = pd.read_csv(url)

# Mostrar las primeras 5 filas para verificar la carga
print("Datos cargados exitosamente. Primeras 5 filas:")
df.head()
```

```
Datos cargados exitosamente. Primeras 5 filas:
```

	UDI	Product ID	Type	Air temperature [K]	Process temperature [K]	Rotational speed [rpm]	Torque [Nm]	Tool wear [min]	Machine failure	TWF	HDF	PWF	OSF	RNF
0	1	M14860	M	298.1	308.6	1551	42.8	0	0	0	0	0	0	0
1	2	L47181	L	298.2	308.7	1408	46.3	3	0	0	0	0	0	0
2	3	L47182	L	298.1	308.5	1498	49.4	5	0	0	0	0	0	0
3	4	L47183	L	298.2	308.6	1433	39.5	7	0	0	0	0	0	0
4	5	L47184	L	298.2	308.7	1408	40.0	9	0	0	0	0	0	0

1. **Análisis de Pesos:** Si el modelo indica que los errores en la Clase 1 (Fallo) pesaran aproximadamente 14.7 veces más que en la Clase 0, ¿qué intenta corregir el algoritmo al configurar el parámetro class_weight durante el entrenamiento?

Rta: Al ajustar el parámetro class_weight, el método busca solucionar el desequilibrio de clases en el conjunto de datos. En este caso particular, dado que hay muchas más muestras de "No Falla" (9661) en comparación con las de

"Falla" (339), el sistema tiende a pasar por alto la clase menos frecuente. Al otorgar un peso 14. 7 veces superior a la Clase 1, el método dificulta los errores en la identificación de fallos, forzando al modelo a concentrarse más en los patrones que indican una posible avería.

2. **La Trampa de la Exactitud:** Explique por qu´e en este caso un *Accuracy* del 95% podr´ıa considerarse un resultado deficiente para la gesti´on de mantenimiento si el modelo no logra detectar los fallos reales.

Rta: Un porcentaje de precisión del 95% puede verse como un mal resultado en este escenario, ya que no muestra la verdadera efectividad del modelo. Si el 96. 6% de la información pertenece a "Operación Normal", un modelo básico que siempre prediga "sin fallos" obtendría un 96. 6% de precisión, pero no sería útil para la supervisión del mantenimiento, puesto que no identificaría ninguna falla. Para una planta industrial, es mejor contar con un modelo que tenga una precisión más baja pero una gran capacidad para detectar fallos reales (Sensibilidad).

- **Interpretación de la Matriz de Confusión:**
  Utilice la matriz de confusión generada por el *heatmap* de Seaborn en su notebook para completar el siguiente análisis. Suponga que, para su planta de producción, el costo de una **reparación no planificada** (Fallo Real no detectado) es de USD 5,000 y el costo de una **inspección preventiva innecesaria** (Falsa Alarma) es de USD 200.

Tarea de Cálculo de Métricas: A partir de los valores obtenidos en su matriz de confusión (TN, FP, FN, TP), calcule manualmente:

1. **Precisión (Precisión):**$\frac{TP}{TP+FP}$— ¿Que tan confiable es el modelo cuando emite una alerta de falla?

   Rta: $\frac{66}{66+0} = 1.00(100\%)$. El modelo es extremadamente confiable; cuando emite una alerta, existe una seguridad total de que se trata de un fallo real.

2. **Recall (Sensibilidad):**$\frac{TP}{TP+FN}$ — ¿Qué porcentaje de los fallos reales totales logró capturar el modelo?

   Rta: $\frac{66}{66+2} = 0.9706$ (97.06%). El modelo logró capturar el 97.06% de todos los fallos reales ocurridos en el set de prueba.

3. **Costo Total de Error:** Calcule el impacto económico mensual del modelo utilizando la fórmula:

$$Costo = (2\ x\ 500) + (0\ x\ 200) = usd\ 10{,}000$$

Preguntas de Reflexión y Negocio Fase 5:

- **Trade-off entre Recall y Precisión:** En el contexto de evitar paradas de línea críticas, ¿preferiría usted un modelo con un *Recall* del 98% pero una *Precisión* del 60%, o viceversa? Justifique su respuesta basándose en los costos calculados anteriormente.

Rta: Un Recall alto (98%) indica que únicamente se pierde el 2% de las fallas (FN). En términos de costos, un único Fallo Real que no se identifica tiene un valor de USD 5,000, mientras que una Falsa Alarma presenta un costo de solo USD 200. Resulta más favorable económicamente llevar a cabo 25 inspecciones preventivas que no son necesarias (25 x 200 = 5,000) en lugar de dejar que una máquina falle sin previo aviso.

- **Curva de Aprendizaje:** Observe la gráfica de *loss* (perdida) y *accuracy* durante el entrenamiento. ¿Considera que 30 ´épocas son suficientes para que el modelo converja? ¿Qué sucede con el error de validación comparado con el de entrenamiento?

Rta: Convergencia: Parece que 30 épocas son adecuadas. Al examinar el registro, se puede notar que el error de entrenamiento disminuye de manera pronunciada y se estabiliza alrededor de las épocas 15 a 20.

Error de Validación: El error de validación se mantiene muy similar al de entrenamiento, finalizando en 0. 0229 y 0. 0732 respectivamente. Esto sugiere que el modelo no sufre de un sobreajuste notable y se adapta bien a datos jamás vistos.

- **Conclusión Final del Taller:** Tras recorrer desde la regresión analítica hasta la clasificación con redes neuronales, ¿cómo puede el uso de métricas avanzadas (como el Recall) transformar la rentabilidad de una empresa de manufactura?

Rta: El empleo de métricas avanzadas como el Recall cambia la rentabilidad al conectar los objetivos del modelo de IA con los costos reales de la empresa. En el sector manufacturero, posibilita la transición de un mantenimiento reactivo, que es costoso, a uno preventivo más eficiente, lo que disminuye de manera significativa el impacto financiero de las paradas imprevistas, lo cual resulta ser mucho más valioso que solo contar con un modelo "exacto" que no sirve para evitar crisis.